

Le Traitement du langage naturel (NLP)

AlForYou - Morgan Gautherot




Chaîne You Tube



Le Traitement du langage naturel (NLP)

AlForYou - Morgan Gautherot




Le Big Data

Seulement 21% de ces données sont structurées !


BIG DATA



Les catégories de données



Le texte dans le big data















Langage informatique



Langage naturel



Natural Language Processing (NLP)



Le traitement naturel du langage

Text

e

On t'a dit : « La vie est courte et tu vas vite en faire le tour. » On t'a dit : « Ne courbe jamais l'échine, cours, ma fille, cours... »

Et dans cette course folle, t'as rencontré bien des malheurs. Car pour courir à mille à l'heure il fallait pendre des valeurs.

Et puisqu'aimer, c'est prendre des risques, toi, tu braves les interdits, On t'a dit : « Faut bien te conduire », t'as répondu : « J'ai pas le permis ! »

> Insolente, lentement, je te voix dévaler la pente, Si tu te révais présidente, tu ne seras que figurante.

Petite sœur, tu veux de l'or, des bolides et des sapes, Toujours dehors, toi, la vie, tu ne la vis plus, tu la snapes.

Au-dessus de toi, tu vois les stars mais tu ne vois plus le ciel, Devenir celle dont tout le monde parle serait pour toi le casse du siècle.

Envie de gloire obsessionnelle, de garde-robe exceptionnelle, Pour l'ascension professionnelle, l'honneur te sera optionnel.

Dans ce monde que tu convoltes, pour être un homme faut être prince, La place qu'il reste est si étroite que pour être star faut être mince.

Tu vois des liasses, tu vois du rêve mais ça n'est que de la poussière. Certes is brassent, mais ils n'aveuglent que ceux qui craignent la lumière.

Tes modèles ne montrent d'eux que lorsqu'ils baignent dans l'opulence, Dans le silence ils taillent leurs veines et déambulent en ambulance.

> À trop courir après du vent, t'en oublieras le Divin, Au suivant ! Tu finiras par parler seule sur un divan.

Crois-moi, quoi que tu gagnes, tu finis insatiable, Toi qui aimais que tout le monde t'aime, tu finiras associable.


Contre un « je t'aime, je m'engage », tu donneras ton cœur en gage, Tu vieilliras juoqu'à ce qu'il parte avec une femme plus jeune en âge.

Car c'est l'histoire qui se répéte, toi qui voudrais changer de nom, Commence par le changer toi-même et lu pourras changer le monde.

- MÉLANIE DITE DIAM'S -


THE MELEYMELISM ! V B-

Données exploitables




Modèle

S






Evolution des méthodologies




Traduction automatique




Génération de textes

Auto complétion




13


Résumé automatique



Chatbot



Analyse du sentiment



Sommaire


Partie 1 : Prétraiter les données textuelles

Partie 2 : Transformer les données textuelles

Partie 3 : Modélisation des données textuelles

Normalisation des données textuelles

AlForYou - Morgan Gautherot



Exploration d'un corpus de texte

- ► Fréquence des mots
- La combinaison des mots
- La richesse du vocabulaire employé
- ► Le distribution du register

•••



Tu me donnes envie de faire table rase du passé, et de t'aider à faire table rase du tien. Tu me donnes envie d'être pour toi ce que je n'ai jamais su être pour quelqu'un d'autre. Tu me donnes envie de t'offrir mon cœur, mes ambitions, mon amour sur un plateau d'argent. Tu me donnes envie de t'aimer à en faire trembler le monde entier. Tu me donnes envie de parler de sentiments et de bonheur tout en conjuguant mes verbes au présent. Tu me donnes envie de devenir quelqu'un qui t'apportera fierté et douceur. Tu me donnes envie de décrocher la Lune, de croire en l'impossible. Tu me donnes envie de vivre, bordel. Parce que tu es l'étincelle au fond de mes yeux, mon sourire terriblement sincère. Parce que je ne suis plus seule désormais, tu es là. Et c'est si précieux.

Le supermarché

Sophie fait les courses au supermarché avec son neveu Clément. Après avoir garé as voiture our le parking, elle a pris un chariot dans lequel Clément s'est installé. Tous deux pénètrent maintenant dans le magasin. Les clients sont nombreux à cause des promotions et des soldes. Sophie sort sa liste des courses pour ne rien oublier. Elle regarde les morques et compare les prix. Elle choisit des produits frais, des conserves et du poisson surgelé qu'elle met dans son chariot. Clément est turbulent, il s'agite sur son siège, il ne cesse de réclamer des bonbons, des biscuits, du chocolat, des jouets. Sophie le grande gentiment puis elle regarde sa montre, il est déjà seize heures. Elle doit se hôter de rentrer cor ce soir elle est invitée avec Jean à dîner chez la momon de Clément, so soour Lucie. Sophie termine les courses, elle se dirige vers la coisse où elle attend colmement son tour. A la coisse, elle place ses achats sur le tapis roulant puis elle rèale sa note avec sa carte bancaire. A présent, elle regagne le parking, cherche quelques instants sa voiture. Elle la repère au fond de l'allée puis se dirige vers son véhicule. Elle ouvre le coffre et y met les courses puis elle installe Clément dans son siège pour enfant. Elle part retrouver Jean et se préparer pour la soirée.

191.Collective.com

006

L'AMITIÉ

L'amitié est un repère, une ligne d'horizon. Une lumière et une porte secrète vers les émotions... Elle nous aide par temps durs, elle fait rire, elle rassure. Elle ne juge pas, elle accepte, elle est là... Tantôt près, tantôt loin, mais toujours à distance de coeurs, notre amitié c'est du bonheur. Notre amitié, c'est une plante que je cultive avec grands soins, le trésor de mon petit jardin. Une pierre précieuse qui m'éclaire dans le noir, et quelqu'un qui connaît toute mon histoire... J'avance sur mon chemin, tu avances sur le tien. L'horizon devant nous est infini, tout comme notre amitié, merci.

On i's dit: « Le vie est courte et tu ves site en faire le tout » On i's dit: « Ne sourbe jemais l'exhine, sours, me fille, sours, ... Et deux ente couves folle, s'encontré laine des malheurs. Cer pour pour à mille à l'haure à follait people des valores.

Et puisqu'aimer, s'est prendre des rioques, toi, tu braves las intendits, On t'a dit : « Faut bien te conduire », t'as répondu : « J'ai pas le parmis ! »

> Insolante, lantement, je te vois dévaler la pante, Si to te néveis présidente, tu ne seres que figurante

Petite sœur, tu veux de l'or, des bolides et des sapes, Toujours dehars, toi, la vie, tu ne la vis plus, tu le snepes

Au-dessus de toi, to vois les sters mais tu ne vois plus le cief. Devenir selle dont tout le monde parle serait pour toi le cause du siècle

Ensie de glaire stoessionnelle, de garde-robe exceptionnelle, Pour l'assension professionnelle, l'honneur te sere aptionnel. Dans ce monde que tu convoltes, pour être un homme faut être prince

La place qu'il reste est si étraite que pour être star faut être minos.

Tu vois des liasses, tu vois du rêve mais ça n'est que de la poussière.

Centes la brassent, mais la n'aveuglent que ceux qui craignent la lumière. Tes modifies ne montent d'eux que lorsqu'ils belgrent dera l'apulence, Dans le altenze ils talièret leux quince et désentuées en ambulance.

> À trop courir agnès du vent, t'en oublieres le Divin Au suivent ! Tu finires par parler seule sur un diven

Croix-moi, quoi que tu gagnes, tu finis insatiable. Toi qui aimais que tout la monde Calme, tu finina associable.

Contre un » je t'aime, je m'engege », tu donneres ton cœur en gege, Tu vieillinse jungu'è ce qu'il parte avec une femme plus jeune en êge.

Cer c'est l'histoire qui se répête, toi qui voudrais changer de nom, Commence par le shanger loi-même et lu pourres changer le monde.

- MÉLANIE DITE DIAM'S

La tokenization

Transformer un texte en vecteur de mots

« Le machine learning est un apprentissage par minimisation de l'erreur!»



```
['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']
```

La normalisation

Suppression de la ponctuation, enlever les apostrophes, mettre en minuscule.

```
['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']
```

['le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'le', 'erreur']

Les stop words

Les mots de liaison qui n'apporte pas de sens mais du bruit

```
['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']
```



```
[ 'machine', 'learning', 'apprentissage', 'minimisation', 'erreur']
```

Doublons

Plusieurs mots avec le même sens mais une orthographe différentes.

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['grand', 'grande', 'grands']

Lemmatisation

Transformer un mot en son sens radical (lemme)

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['grand', 'grand', 'grand']

Stemming

Supprimer la fin des mots

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['gran', 'gran', 'gran']

Prétraitements essentielles

▶ Tokenization

Normalisation

Suppression des stop words

Lemmatisation / Stemming

Collocation

Lier les mots qui apparaissent souvent ensemble

« Je lis souvent le New-York times »



- « New-York » +

Part of speech tagging

Ajouter des précision sur le mot

« J'aime chevaucher des chevaux »



Chevaux → Chevaux/NOM

Chevaucher → Chevaucher/VER:infi

Natural Langauge ToolKit (NLTK)

NLTK 3.5 documentation

NEXT | MODULES | INDEX

Natural Language Toolkit

NLTK is a leading platform for building Python programs to work with human language data. It provides easy-to-use interfaces to <u>over 50 corpora and lexical resources</u> such as WordNet, along with a suite of text processing libraries for classification, tokenization, stemming, tagging, parsing, and semantic reasoning, wrappers for industrial-strength NLP libraries, and an active <u>discussion forum</u>.

Thanks to a hands-on guide introducing programming fundamentals alongside topics in computational linguistics, plus comprehensive API documentation, NLTK is suitable for linguists, engineers, students, educators, researchers, and industry users alike. NLTK is available for Windows, Mac OS X, and Linux. Best of all, NLTK is a free, open source, community-driven project.

NLTK has been called "a wonderful tool for teaching, and working in, computational linguistics using Python," and "an amazing library to play with natural language."

Natural Language Processing with Python provides a practical introduction to programming for language processing. Written by the creators of NLTK, it guides the reader through the fundamentals of writing Python programs, working with corpora, categorizing text, analyzing linguistic structure, and more. The online version of the book has been been updated for Python 3 and NLTK 3. (The original Python 2 version is still available at http://nltk.org/book_led.)

Some simple things you can do with NLTK


TABLE OF CONTENTS

NLTK News	
Installing NLTK	
Installing NLTK Data	
Contribute to NLTK	
FAQ	
Wiki	
API	
ноwто	

SEARCH

Go

Google colab



Notebook 1 - Se familiariser avec NLTK

Objectif:

- Utiliser Python pour travailler des données textuelles
- Apprendre à utiliser NLTK pour transformer un texte
- Implémenter un détecteur de langue avec les stopwords